Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Estado de México

Proyecto Final: Analítica de Datos

Aldo Martínez Hernández

Arleth Magali Sosa García

Profesores: **ADOLFO CENTENO TELLEZ**

Q3001B.502

Desarrollo de proyectos de nanotecnología

1. INTRODUCCIÓN

En la actualidad, el análisis de datos se ha convertido en una herramienta fundamental para la toma de decisiones informadas en múltiples sectores, desde el ámbito gubernamental hasta el empresarial y científico. La creciente disponibilidad de fuentes de datos abiertos y estructurados ha impulsado el desarrollo de proyectos orientados a la obtención de conocimiento útil a partir de grandes volúmenes de información, mediante técnicas de minería de datos, estadística y aprendizaje automático. Dentro del contexto del presente proyecto, el análisis de datos permitirá identificar patrones, tendencias o relaciones relevantes que de otra forma serían difíciles de detectar. Para lograrlo, es crucial considerar no solo las herramientas computacionales a utilizar (como Python, Pandas o herramientas de visualización como Tableau o Power BI), sino también las fuentes de datos y su transformación adecuada para cumplir con los objetivos del análisis.

Fuentes como datos.gob.mx (plataforma del gobierno de México para datos abiertos) [1], el Instituto Nacional de Estadística y Geografía (INEGI) [2] o portales de datos legislativos como los del Congreso de la Unión representan puntos de partida confiables y actualizados para obtener conjuntos de datos relacionados con temáticas nacionales. Asimismo, repositorios internacionales como Kaggle, el World Bank Open Data o OECD Data pueden complementar estos recursos en función del enfoque del proyecto.

La preparación de estos datos frecuentemente implica tareas de transformación como limpieza, normalización, filtrado de columnas irrelevantes, tratamiento de valores faltantes o duplicados, y codificación de variables categóricas. Estas etapas son esenciales para garantizar la calidad del análisis posterior y se alinean con las mejores prácticas propuestas por metodologías como CRISP-DM [3], ampliamente adoptada en proyectos de ciencia de datos.

En particular, este proyecto tiene como finalidad explorar una base de datos pública proveniente del Instituto Nacional Electoral (INE), específicamente del Programa de Resultados Electorales Preliminares (PREP) correspondiente a la elección de diputados federales del año 2015 [4]. Dicha base de datos permite un acercamiento analítico a los resultados preliminares de una elección federal, considerando variables geográficas, partidistas y de participación. A través de su análisis, se pretende generar una visión más clara del comportamiento electoral de ese periodo, utilizando para ello herramientas computacionales modernas.

El análisis será realizado mediante Python, una de las herramientas más versátiles en ciencia de datos, que permite tanto la transformación de datos con librerías como Pandas y NumPy, como su visualización efectiva a través de bibliotecas como Matplotlib. El propósito es elaborar reportes, generar estadísticas descriptivas y construir visualizaciones que apoyen la comprensión de la información, facilitando así una lectura crítica de los datos electorales.

Este documento tiene como objetivo explorar las posibles fuentes de datos que podrían integrarse al proyecto, así como los procesos necesarios para su transformación y adecuación. Este enfoque garantiza una base sólida para realizar un análisis significativo y alineado con los objetivos planteados por el equipo, fomentando así el desarrollo de competencias técnicas y analíticas aplicadas a un caso real de interés nacional.

2. DESCRIPCIÓN DETALLADA DEL PROBLEMA

En el contexto de los procesos electorales en México, existe una gran cantidad de datos generados por instituciones como el Instituto Nacional Electoral (INE), especialmente a través de programas como el PREP (Programa de Resultados Electorales Preliminares). Sin embargo, aunque estos datos son públicos y accesibles, su volumen, formato técnico y nivel de desagregación dificultan su comprensión y algunas veces el acceso de estos documentos de gran volumen es difícil para personas que solo cuentan con un teléfono móvil. La información se presenta generalmente en archivos extensos, con términos específicos y sin elementos visuales que faciliten su interpretación. Esta situación genera una brecha entre la disponibilidad de información electoral y su aprovechamiento efectivo por parte de la sociedad.

3. STAKEHOLDERS

De acuerdo al enfoque del proyecto las personas interesadas serían los ciudadanos mexicanos interesados en política y elecciones, ya que son quienes buscan información de forma accesible y sencilla para mantenerse informados, Se benefician de una herramienta clara, visual y accesible para interpretar datos que de otro modo serían difíciles de analizar o sería muy tardado buscar los datos de un sector en toda la base de datos.

4. METODOLOGÍA

Para el desarrollo de este proyecto no fue necesario realizar algún cambio a la base de datos, ya que esta estaba estructurada de una forma sencilla y aparte para la implementación en el programa.

El desarrollo del proyecto se estructuró en varias etapas clave, utilizando programación en Python para analizar y visualizar los resultados electorales del año 2015 en México. A continuación, se describe detalladamente cómo se implementó el sistema, las funciones utilizadas y la lógica detrás de cada módulo del programa.

A. *Entrada de datos y validación inicial.*

Al comenzar el programa, se presenta un menú inicial con las opciones [1. Estadísticas, 2. Reportes, 3. Gráficas, 0. Salir]. Para ingresar una de estas opciones, se utiliza la función input(). Para asegurar que el valor ingresado sea válido, se aplica la función “ isdecimal()” para comprobar que la entrada sea un número entero positivo, y luego se verifica si está dentro del rango permitido (0 a 4). Esta validación se realiza dentro de un ciclo while, que se

repite hasta que se proporcione un valor correcto. En caso de error, se muestra el mensaje: "Error, debe ingresar un número entero sin caracteres especiales."

B. Ciclo principal del menú.

El menú principal está controlado por un ciclo while que permite al usuario elegir entre las tres opciones de análisis mientras no ingrese el número 0 (que indica salir). Cada opción dirige al usuario a un módulo específico

C. Módulo 1.

Al seleccionar esta opción, el programa realiza lo siguiente:

- Imprime un mensaje indicando que se ingresó al módulo de estadísticas.
- Llama a la función calcular_votos_partido() para calcular la suma total de votos para cada partido político. Esta función utiliza la librería csv, accede al archivo con los datos y recorre sus filas ignorando encabezados y valores inválidos como “Ilegible” o “Sin dato”. Se utilizan contadores separados para cada uno de los 10 partidos.
- Se usa la función max() para determinar el partido con más votos, y min() para el que menos recibió.
- Para calcular la participación ciudadana nacional, se llama a calcular_porcentaje_participación_país(), que suma el total de votos por estado y la lista nominal, para luego calcular el porcentaje de participación.
- Luego, el programa pregunta si el usuario quiere consultar la participación ciudadana de un estado específico. Si acepta, se solicita el nombre del estado en mayúsculas (con acentos correctos) y se ejecuta la función calcular_porcentaje_participación(estado). Esta analiza solo los renglones que correspondan al estado, y si hay errores de escritura, se devuelve 0 para evitar divisiones inválidas.
- Para asegurar el retorno correcto al menú, tras cada acción o error, se asigna el valor 4 a la variable que controla el menú.

D. Módulo 2.

Si el usuario selecciona la opción 2, accede a los reportes:

- Se muestran automáticamente el total de votos del país (calcular_votos_pais()), el total de votos anulados (calcular_votos_anulados()), y los votos de cada partido (asignar_nombre_partido(partido)).
- El usuario puede consultar el total de votos de un estado específico. Si acepta, se pide el nombre del estado y se ejecuta calcular_votos_estado(estado), que suma los votos para ese estado.
- También puede consultar cuántos votos obtuvo un partido en un estado, usando la función calcular_votos_partido_estado(partido, estado). Aquí se validan tanto el número del partido como el nombre del estado.
- Errores de entrada provocan un retorno automático al menú principal asignando nuevamente el valor 4.

E. Módulo 3.

Si se selecciona la opción 3, el programa permite generar diferentes tipos de gráficas usando matplotlib.pyplot:

- Se le pregunta al usuario qué tipo de gráfica quiere ver: 0: Total de votos por estado (gráfica de barras).
    - 1: Total de votos por partido (gráfica de barras).
    - 2: Porcentaje de votos por partido (gráfica de pastel).
    - 3: Participación ciudadana del país (barras).
    - 4: Porcentaje de participación ciudadana (pastel).
- Dependiendo de la opción, se llama a graficar_graficas_default(opcion), que prepara los datos correspondientes y los visualiza:
    - Para las barras, se utiliza plot.bar con etiquetas y valores personalizados.
    - Para los gráficos de pastel, se usa plot.pie con autopct para mostrar porcentajes y labels para etiquetas.
    - Se configura el formato de los gráficos (título, etiquetas, colores, etc.) con funciones como plot.title(), plot.ylabel(), plot.grid(), plot.xticks() y plot.show().
- Si el usuario introduce una opción inválida, el programa muestra un error y regresa al menú.

F. Cierre del programa.

Si el usuario ingresa el número 0, el ciclo while termina. El programa imprime un mensaje de despedida: “Gracias por haber ingresado a la base de datos del conteo electoral. Que tenga un buen día :)” Y finaliza su ejecución.

5. DESCRIPCIÓN DE LAS VARIABLES

   La base de datos utilizada en este proyecto contiene información del Programa de Resultados Electorales Preliminares (PREP) correspondiente a las elecciones federales de México en 2015. Cada fila representa una casilla electoral, y las columnas corresponden a diferentes variables asociadas a los resultados de votación. A continuación, se describen las variables utilizadas en este análisis:

Información geográfica y organizativa

- **ID_ESTADO**: Clave numérica asignada a cada estado.
- **ESTADO**: Nombre de la entidad federativa correspondiente al registro.
- **ID_DISTRITO**: Identificador numérico del distrito electoral federal.
- **DISTRITO**: Número del distrito electoral.
- **SECCION**: Clave numérica de la sección electoral dentro del distrito.

- **ID_CASILLA**: Identificador único de la casilla.
- **TIPO_CASILLA**: Tipo de casilla (Básica, Contigua, Especial, Extraordinaria).
- **EXT_CONTIGUA**: Indica si es una casilla contigua (cuando se instalan varias en la misma sección).
- **UBICACION_CASILLA**: Dirección física de la casilla electoral.

Información del acta

- **TIPO_ACTA**: Tipo de acta capturada (por ejemplo, PREP o acta complementaria).
- **NUM_BOLETAS_SOBRANTES**: Número de boletas no utilizadas en la casilla.
- **NUM_BOLETAS_EXTRAIDAS**: Número de boletas retiradas de la urna (usadas).

Resultados de votación por partido y otras opciones

- **PAN, PRI, PRD, PVEM, PT, MOVIMIENTO_CIUDADANO, NUEVA_ALIANZA, MORENA, PARTIDO_HUMANISTA, ENCUENTRO_SOCIAL**: Columnas que indican la cantidad de votos recibidos por cada uno de los partidos políticos registrados.
- **PRI_PVEM, PRD_PT**: Votos obtenidos por coaliciones entre partidos.
- **CAND_IND_1, CAND_IND_2**: Votos para candidatos independientes (si los hubo en esa casilla).
- **NO_REGISTRADOS**: Votos emitidos a candidatos no registrados.
- **NULOS**: Boletas anuladas por errores de llenado o marcadas incorrectamente.
- **TOTAL_VOTOS**: Suma total de los votos válidos y nulos emitidos en la casilla.

Datos adicionales

- **TOTAL_CIUDADANOS_VOTARON**: Total de personas que acudieron a votar en la casilla.
- **LISTA_NOMINAL**: Número de personas registradas para votar en esa casilla.
- **OBSERVACIONES**: Campo de texto que puede contener notas específicas o incidencias observadas en la casilla.
- **CONTABILIZADA**: Indica si el acta fue contabilizada oficialmente o no

Para este proyecto, las variables más utilizadas fueron: **ESTADO**, **LISTA_NOMINAL**, **TOTAL_VOTOS**, **NULOS**, y los campos de cada partido político (como **PAN**, **PRI**, **MORENA**, etc.). Estas se emplearon para generar estadísticas por estado, calcular la participación ciudadana, identificar al partido más votado y visualizar la información en gráficas.

6. RESULTADOS

Durante el análisis de los datos electorales correspondientes al proceso electoral federal de México en 2015, se aplicaron técnicas de limpieza, validación y agrupamiento de datos mediante programación en Python, con el objetivo de extraer patrones relevantes, calcular estadísticas clave y facilitar la interpretación de la información mediante gráficas interactivas.

A continuación, se resumen los principales hallazgos y descubrimientos del análisis:

Participación ciudadana

La participación ciudadana nacional fue de aproximadamente 44.05%, calculada como el cociente entre el total de ciudadanos que votaron y la lista nominal agregada. A nivel estatal, el Distrito Federal presentó la mayor participación ciudadana, mientras que Colima registró la más baja, evidenciando diferencias significativas entre entidades federativas. En algunas casillas, la participación fue inusualmente baja o igual a cero, lo que puede sugerir errores en el registro de datos, problemas logísticos o incluso falta de votantes.

Resultados por partido político

El partido político con mayor número de votos a nivel nacional fue el Partido Revolucionario Institucional (PRI) con 10,496,135 votos. El partido con menor número de votos fue el Partido Humanista, con 790,497 votos.

Se utilizó la función calcular_votos_partido() para determinar la suma total de votos por cada partido. Este análisis mostró una fuerte concentración de votos en los partidos tradicionales, con menor representación de partidos pequeños o nuevos. Las coaliciones PRI-PVEM y PRD-PT obtuvieron resultados significativos en distritos clave, indicando que las alianzas entre partidos jugaron un papel importante en ciertos estados.

Comparativas por estado

El PRI tuvo una presencia particularmente fuerte en el Estado de México, obteniendo una proporción considerable de votos en esa entidad. Los votos por candidatos independientes fueron en general bajos, lo cual sugiere una baja penetración o visibilidad de este tipo de candidaturas en el electorado.

Gráficas y visualizaciones

Las visualizaciones generadas permitieron representar de manera clara los resultados del análisis:

Gráficas de barras para mostrar el total de votos por partido y por estado. Gráficas de pastel para representar proporciones relativas, como el porcentaje de participación ciudadana o la distribución del voto entre partidos.

Estas gráficas facilitaron la interpretación visual de los datos y ayudaron a detectar patrones de forma más accesible.

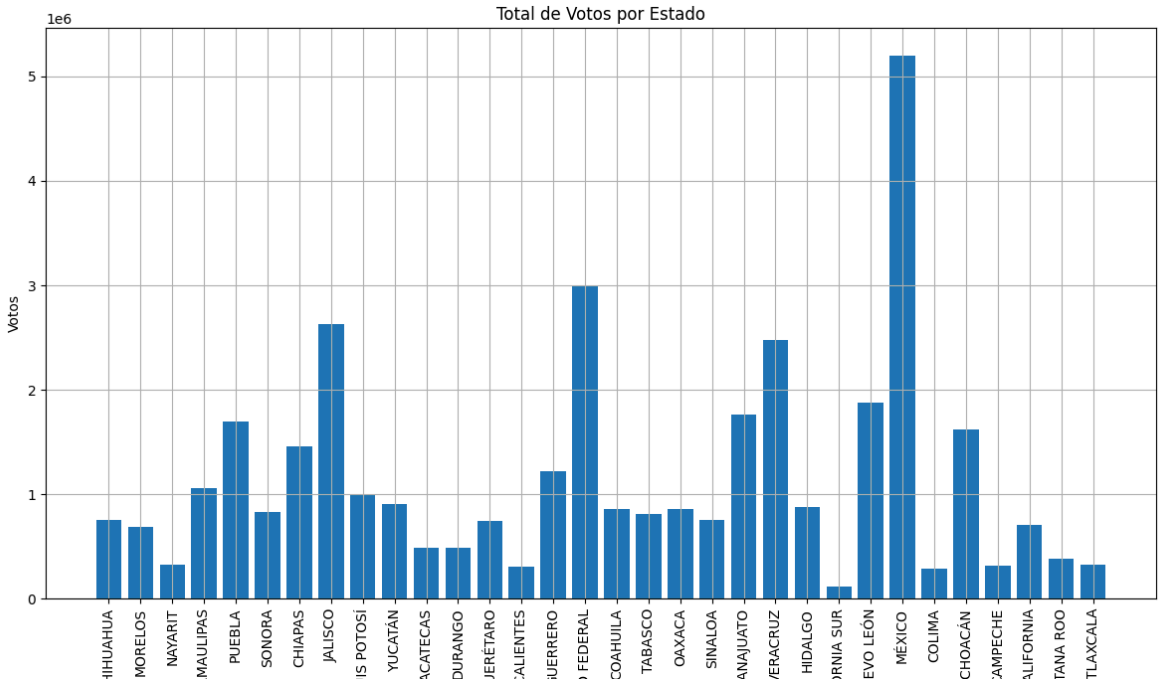

Figura 1. Total de votos por estado en el país durante las elecciones para la posición de diputado en 2015.

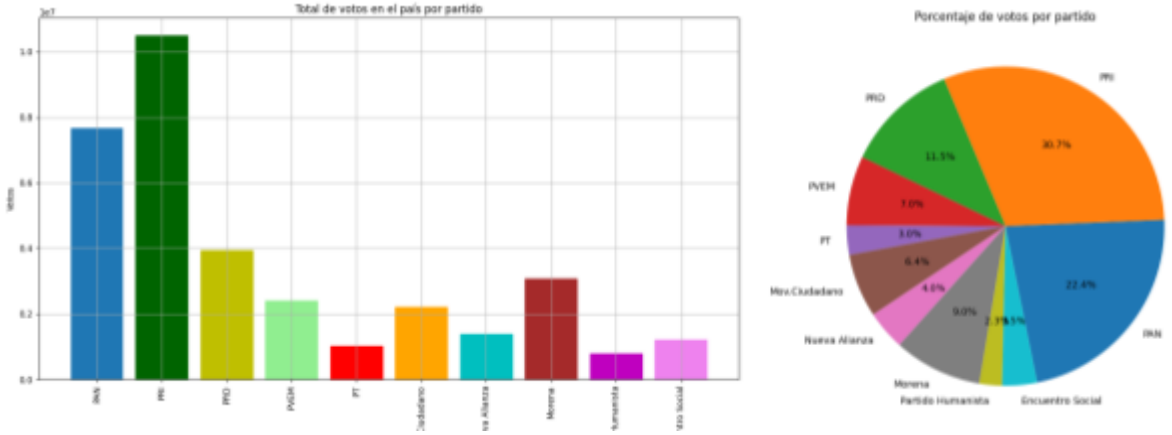

Figura 2. Total de votos en el país por partido (Izquierda) y porcentaje de votos por partido (Derecha).

Observaciones adicionales

Se encontraron valores inválidos o inconsistentes, como “Ilegible” o “Sin dato”, que fueron ignorados durante el análisis para evitar errores en cálculos y gráficas. En algunas casillas, el número de votos excede el de la lista nominal o presentaba inconsistencias lógicas. Estos casos fueron tratados mediante validaciones dentro del código para garantizar resultados confiables.

7. EVALUACIÓN DE RESULTADOS

Los resultados obtenidos a través del análisis de los datos electorales de 2015 ofrecen un valor significativo desde distintas perspectivas:

Valor político y social

El análisis permitió identificar los niveles de participación ciudadana por estado y a nivel nacional, lo cual es fundamental para evaluar el grado de involucramiento democrático de la población en dicho proceso electoral.

La detección de estados con baja participación, como Colima, puede orientar futuras estrategias de movilización ciudadana y campañas para fomentar el voto informado.

Asimismo, observar una fuerte presencia de ciertos partidos en regiones específicas, como el PRI en el Estado de México, permite comprender la distribución geográfica del poder político, lo cual puede influir en decisiones estratégicas de campaña en elecciones futuras.

Valor para la transparencia electoral

El cruce de datos entre ciudadanos que votaron, boletas sobrantes y boletas extraídas contribuye a identificar posibles inconsistencias o anomalías en las casillas, lo que refuerza la transparencia del proceso electoral.

Casillas con participación igual a cero o con más votos que personas en la lista nominal pueden señalar errores administrativos o situaciones atípicas que requieren revisión o supervisión.

Valor analítico y académico

Este análisis representa un caso práctico del uso de herramientas de ciencia de datos aplicadas a información pública, demostrando cómo técnicas básicas de programación y visualización pueden generar hallazgos relevantes a partir de una base de datos compleja.

Asimismo, ofrece una base útil para futuras investigaciones que deseen realizar análisis comparativos entre distintos procesos electorales, evaluar la evolución de la participación ciudadana o estudiar el impacto de nuevas fuerzas políticas.

Potencial de mejora

Este tipo de análisis puede ser fortalecido mediante la implementación de modelos predictivos o segmentaciones más profundas, por ejemplo, explorando relaciones entre la participación electoral y variables sociodemográficas, o aplicando algoritmos de detección de anomalías para identificar casillas atípicas de manera automatizada.

En conjunto, los resultados obtenidos tienen un alto valor práctico y estratégico, tanto para el análisis político-electoral como para el fortalecimiento de la transparencia y la participación democrática en México.

8. REFLEXIÓN DEL VALOR AGREGADO

El desarrollo de este proyecto no solo permitió analizar los resultados electorales de manera estructurada, sino que también generó un valor agregado significativo en términos de habilidades técnicas, comprensión cívica y aprovechamiento de los datos públicos. En primer lugar, el proceso de limpieza, validación y análisis de los datos electorales ofreció una experiencia concreta en el manejo de bases de datos reales, caracterizadas por su volumen, complejidad y posibles inconsistencias. Esto reforzó el conocimiento práctico sobre programación en Python, el uso de bibliotecas como csv y matplotlib, y el diseño de estructuras lógicas robustas para la interacción con el usuario.

En segundo lugar, el análisis permitió visualizar de forma clara y accesible patrones y tendencias en la participación ciudadana y en la distribución de votos entre partidos políticos. Este valor informativo se traduce en una herramienta útil para la ciudadanía, para investigadores y para actores políticos que buscan comprender mejor la dinámica electoral del país. Además, el proyecto promueve una cultura de rendición de cuentas y transparencia, al demostrar cómo los datos públicos pueden ser utilizados para realizar un monitoreo independiente y técnico de los procesos democráticos. El valor agregado radica en que, a través de la tecnología, es posible acercar la información electoral a un público más amplio, generando conciencia crítica y fomentando la participación informada.

Finalmente, este trabajo representa una oportunidad de innovación al vincular la programación con temas de interés social. El desarrollo de herramientas personalizadas para explorar los datos electorales abre la posibilidad de crear sistemas más complejos que apoyen la toma de decisiones, la educación cívica y el fortalecimiento de la democracia. En conjunto, el valor agregado del proyecto se manifiesta en la integración de habilidades técnicas con un enfoque socialmente relevante, potenciando el uso responsable y estratégico de la información electoral.

9. BIBLIOGRAFÍA

[1] Instituto Nacional para el Federalismo y el Desarrollo Municipal. (s.f.). *Datos Abiertos*. gob.mx. https://www.gob.mx/inafed/documentos/datos-abiertos-347532

[2] Instituto Nacional de Estadística y Geografía (INEGI). (s.f.). *INEGI*. https://www.inegi.org.mx/

[3] Shearer, C. (2000). *The CRISP-DM Model: The New Blueprint for Data Mining*. Journal of Data Warehousing.

[4] Instituto Nacional Electoral. (2015). *Base de datos | PREP*. PREP 2015. https://prep2015.ine.mx/BaseDeDatos.html

10. ANEXOS

A continuación se presenta en su totalidad un enlace con dirección directa al código de la síntesis de la base de datos realizada en Python:
https://drive.google.com/file/d/1vNizpv9w9PDjc0mwQ0LueX8YjHEICNmi/view?usp=sharing